Mapa de Agentes de IA — Olist Intelligent Marketplace

Tech Challenge Fase 1 — Agentic AI

2026-10-10

Table of contents

1 Contexto **1**

2 Visão geral dos agentes propostos **3**

3 Detalhamento dos Agentes **4**
- 3.1 Agente de Inteligência de Reviews 4
- 3.2 Agente de Risco de Entrega 4
- 3.3 Agente de Performance de Vendedores 5
- 3.4 Agente de Atendimento ao Cliente 6

4 Como os agentes se conectam **7**

5 Próximos passos sugeridos **8**

1 Contexto

A análise exploratória do dataset Olist (`notebooks/analise_exploratoria.ipynb`) revelou sete sinais de negócio fortes o suficiente para justificar, com dados, a priorização de agentes de IA:

1. **Atraso logístico é o maior driver de insatisfação, com relação dose-resposta clara.** A nota média de review cai progressivamente conforme o atraso aumenta:

Faixa de atraso	Pedidos	Nota média
No prazo / adiantado	89.939	4,29
Atraso leve (1-3 dias)	1.856	3,29
Atraso moderado (4-7 dias)	1.756	2,10

Faixa de atraso	Pedidos	Nota média
Atraso severo (8+ dias)	2.797	1,70

Não é um efeito de limiar único — cada faixa adicional de atraso derruba a nota de forma consistente, o que reforça que qualquer intervenção que reduza o atraso, mesmo que não o elimine totalmente, já tem efeito direto mensurável na satisfação. O boxplot de atraso por nota reforça essa leitura de outra forma: **apenas na nota 1 o terceiro quartil (Q3) do atraso é positivo (+6 dias)** — ou seja, só entre quem deu nota 1 existe uma parcela relevante (25%+) que de fato recebeu o pedido atrasado; nas notas 2 a 5, mesmo no pior quartil a entrega ainda ocorre antes do prazo, sinalizando que, para notas intermediárias, outros fatores (além do atraso) também pesam na insatisfação.

Nota metodológica: a nota de review é uma variável **ordinal** (1 a 5), não contínua, então a correlação de Pearson (-0,27) não é a métrica mais adequada — ela assume distância igual entre categorias. Recalculando com **Spearman** (baseada em ranks, correta para dado ordinal e robusta a outliers), a correlação é de **-0,18**: mais moderada, mas confirma a mesma direção e reforça que a tabela de faixas acima — e não um coeficiente único — é a evidência mais honesta da relação.

2. **O problema concentra-se geograficamente e em operações interestaduais.** Estados como AL, MA, SE, PI e CE têm taxa de atraso 2-3x acima da média (6,8%); entregas entre estados diferentes atrasam quase o dobro das intraestaduais (7,8% vs 4,4%).

3. **A base de vendedores é extremamente concentrada e heterogênea.** Os 10% maiores vendedores (309 de 3.095) respondem por 67,5% da receita, e alguns vendedores com volume relevante chegam a 27-50% de taxa de atraso — um risco operacional e de marca que hoje não é monitorado de forma ativa.

4. **Existe um volume relevante de texto não estruturado já sendo gerado pelo cliente.** 41,3% dos reviews trazem comentário escrito, e 14,7% das notas são negativas (~14,6 mil reviews) — um volume grande demais para triagem manual, mas pequeno demais (e repetitivo o suficiente) para não ser automatizável com IA Generativa.

5. **O tempo total de entrega pesa mais na nota do que o cumprimento da promessa de prazo.** Uma análise multivariada comparando a força de associação (Spearman) de 12 variáveis com a nota de review mostra que `delivery_days` (tempo total compra→cliente, -0,234) tem associação **mais forte** do que `delay_days` (desvio do prazo prometido, -0,176). Em seguida aparecem nº de itens no pedido (-0,108), valor do frete (-0,089) e entrega no mesmo estado do vendedor (+0,060). Preço, parcelamento, peso do produto e qualidade do anúncio (fotos/descrição) têm efeito desprezível (|Spearman| < 0,03). Isso é um achado prático importante: **reduzir o tempo absoluto de espera importa tanto ou mais do que apenas "cumprir**

o prometido" — um pedido que chega dentro do prazo mas demora muito ainda machuca a satisfação.

6. **A Olist estima prazos de entrega de forma muito conservadora.** O boxplot do desvio entre a data prometida e a data real mostra mediana de **-12 dias** — ou seja, metade dos pedidos chega 12 dias ou mais *antes* do prazo informado ao cliente (P75 = -7 dias; P90 = -2 dias). A taxa real de atraso é de apenas 6,8%, mas a promessa de prazo é folgada o suficiente para, possivelmente, reduzir conversão (prazos longos demais no checkout) sem necessidade — um ponto de melhoria independente da redução de atraso em si.
7. **A taxa de atraso dispara em picos sazonais de demanda, não é constante ao longo do ano.** A série mensal de pedidos atrasados mostra que a operação não escala bem com picos de volume: **nov/2017 (Black Friday)** teve o maior volume de vendas do período (R$ 1,01 milhão, 7.451 pedidos) e taxa de atraso de **12,4%** — quase o dobro da média geral (6,8%). Fev/2018 (14,1%) e, principalmente, **mar/2018 (19,0%)** foram os piores meses de toda a série. Ou seja, o risco de atraso não depende só de rota/vendedor — depende de **quando** o pedido é feito, e a operação logística atual não absorve bem picos de demanda.

Esses sete sinais mapeiam diretamente para os desafios de negócio citados pela Olist (experiência do cliente, eficiência logística, retenção, análise de reviews, apoio à decisão) e orientam a escolha dos agentes propostos abaixo.

2 Visão geral dos agentes propostos

Table 1: Visão geral dos agentes propostos

#	Agente	Dor de negócio endereçada	Usuário principal
1	Inteligência de Reviews	14,7% de notas negativas, triagem manual inviável	CX / Qualidade
2	Risco de Entrega	Atraso é o maior driver de insatisfação	Logística / Operações
3	Performance de Vendedores	Concentração de receita + atraso desigual entre sellers	Marketplace / Seller Success
4	Atendimento ao Cliente	Volume de pedidos (~100 mil) gera alto custo de suporte	Atendimento ao Cliente

Os quatro agentes compartilham dados (pedidos, entregas, reviews) e se complementam: o Agente de Risco de Entrega alimenta o Agente de Atendimento com previsões de atraso, e o Agente de Performance de Vendedores usa os mesmos sinais de atraso e nota para pontuar sellers. O detalhamento de cada um segue abaixo.

3 Detalhamento dos Agentes

3.1 Agente de Inteligência de Reviews

Objetivo Ler, classificar e resumir automaticamente os comentários de reviews — especialmente os negativos — identificando causa raiz (atraso, produto, atendimento, preço) e gerando um resumo executivo recorrente para a liderança de qualidade.

Problema resolvido Hoje ~14,6 mil reviews negativos por período analisado trazem comentário em texto livre, mas não há como ler e categorizar esse volume manualmente de forma consistente. Problemas recorrentes (ex.: atraso, divergência de produto) só são percebidos tarde, de forma reativa.

Dado que evidencia 14,7% de notas 1-2; 41,3% dos reviews com comentário; termos mais frequentes em reviews negativos — "entrega", "prazo", "contato", "qualidade" — confirmando que atraso e comunicação dominam as queixas.

Usuários envolvidos Time de Qualidade/CX (consome os resumos), gestão de categorias e vendedores (recebe alertas sobre problemas recorrentes por categoria/seller), diretoria (dashboard executivo de satisfação).

Benefício esperado Redução do tempo de identificação de problemas recorrentes, priorização de ações por causa raiz (e não por volume de reclamações isolado), e insumo direto para negociar SLAs com vendedores/categorias problemáticas (ex.: `office_furniture`, pior nota média do dataset).

Riscos Viés de classificação em linguagem informal/regional; necessidade de revisão humana antes de ações automáticas contra vendedores; dados de review podem conter informações pessoais que exigem anonimização.

3.2 Agente de Risco de Entrega

Objetivo Estimar, no momento da compra ou do despacho, o tempo total de entrega esperado e a probabilidade de atraso de um pedido com base em rota (estado origem/destino), vendedor, categoria, nº de itens, **época do ano/volume de demanda** e histórico — gerando (a) alertas proativos para operações e cliente e (b) uma data estimada de entrega mais precisa, dinâmica e curta do que a praticada hoje. O foco não é só "evitar quebrar a promessa", mas **reduzir o tempo total de espera**, que pesa mais na satisfação do que o atraso em si.

Problema resolvido Atrasos hoje são descobertos pelo cliente (e pela Olist) somente quando já ocorreram, sem mecanismo preditivo. Isso transforma um problema operacional evitável em um problema de satisfação já consumado — a nota cai de forma consistente conforme o atraso aumenta (4,29 → 3,29 → 2,10 → 1,70). Mais relevante ainda: a análise multivariada mostra que o tempo total de entrega (`delivery_days`) está mais associado à nota (Spearman -0,234) do que o desvio em relação ao prazo prometido (`delay_days`, -0,176) — ou seja, otimizar apenas para "não atrasar" deixa valor na mesa. Pedidos com mais itens (-0,108) e frete mais caro (-0,089) agravam o problema. Adicionalmente, o prazo hoje comunicado ao cliente é folgado demais (mediana de 12 dias de margem), o que pode custar conversão no checkout sem necessidade. A operação também não escala bem em picos sazon-

ais: a taxa de atraso subiu para 12,4% em nov/2017 (Black Friday, maior volume do período) e chegou a 19,0% em mar/2018 — quase 3x a média geral — mostrando que o risco de atraso depende também de **quando** o pedido é feito, não só de rota e vendedor.

Dado que evidencia Taxa de atraso média de 6,8% (10,6 dias de atraso médio quando ocorre); concentração em estados específicos (AL 21,4%, MA 17,4%, SE 15,2%); entregas interestaduais com quase o dobro da taxa de atraso e do tempo médio de entrega das intraestaduais. Tempo de entrega com mediana de 10 dias mas P90 de 23 dias (cauda longa de outliers); desvio do prazo estimado com mediana de -12 dias, evidenciando folga sistemática na promessa de prazo. Correlação de Spearman com a nota: delivery_days -0,234 (mais forte), delay_days -0,176, nº de itens -0,108, frete -0,089, mesmo estado +0,060. Série mensal: taxa de atraso de 12,4% em nov/2017 e 19,0% em mar/2018, vs. média geral de 6,8%.

Usuários envolvidos Time de Logística/Operações (prioriza pedidos de alto risco), Atendimento ao Cliente (recebe o sinal para comunicação proativa), Time Comercial/Produto (ajusta a promessa de prazo no checkout), cliente final (notificação antecipada em vez de surpresa negativa, e prazo mais realista na compra).

Benefício esperado Redução de reviews negativos associados a atraso via comunicação proativa e priorização operacional; possibilidade de renegociar rota/transportadora nas combinações estado-origem × estado-destino de maior risco antes que o atraso se concretize; e ganho potencial de conversão ao comunicar prazos de entrega mais curtos e precisos (sem abrir mão de margem de segurança) nas rotas de baixo risco.

Riscos Qualidade da previsão depende de dados históricos representativos; falsos positivos podem gerar comunicação desnecessária e desgastar a confiança do cliente no alerta.

3.3 Agente de Performance de Vendedores

Modelo vs. agente — uma distinção importante Calcular taxa de atraso, nota média e um score de risco por vendedor é **analítica/ML tradicional** (uma regra ponderada ou um classificador treinado) — isso, sozinho, não é um agente de IA. A camada **agêntica** começa depois do score: é o componente que lê os comentários de review daquele vendedor (dado não estruturado), diagnostica a causa provável em linguagem natural, decide qual ação recomendar dentre um conjunto de opções, e redige essa recomendação para um humano aprovar. Ou seja: o score/modelo é uma **ferramenta que o agente consulta**, não o agente em si.

```
[Modelo/score de risco do vendedor]  dado  [Agente de Performance de Vendedores]

                                                lê reviews do vendedor (texto l
                                                diagnostica causa provável
                                                decide/redige recomendação de a
```

Objetivo Consolidar, por vendedor, indicadores de atraso, nota média de review e volume num score de risco; diagnosticar a causa provável do problema a partir dos

comentários de review ligados a esse vendedor; e gerar uma recomendação de ação executiva (treinamento, plano de melhoria, suspensão de categorias, revisão de parceria) para aprovação humana.

Problema resolvido A base de vendedores é muito concentrada e desigual — não há hoje um mecanismo sistemático e contínuo de monitoramento que separe os vendedores estruturalmente problemáticos dos pontualmente problemáticos, nem um processo que traduza "esse vendedor está mal" em uma ação concreta e justificada.

Dado que evidencia Os 10% maiores vendedores (309 de 3.095) geram 67,5% da receita; entre vendedores com volume relevante (≥20 pedidos), vários apresentam taxa de atraso entre 27% e 50%, muito acima da média geral de 6,8%.

Exemplo concreto (dado real do dataset) Um vendedor com 25 pedidos entregues e 50% de taxa de atraso geraria uma saída como: *"Vendedor [id] — Risco: CRÍTICO. 25 pedidos nos últimos 90 dias, 50% com atraso (vs. 6,8% da média geral). Causa provável nos comentários: atrasos recorrentes, clientes relatam falta de contato. Recomendação: suspender de categorias de alto volume + notificar plano de melhoria em 15 dias."*

O que acontece com essa informação — importante: não vai direto ao cliente O agente **não alerta o cliente diretamente** sobre o histórico do vendedor — isso corroeria a confiança no marketplace como um todo, e não ajuda quem já comprou. A saída segue dois caminhos:

(1) o score e a recomendação vão para o time de **Seller Success**, que decide a ação de gestão (humano no circuito); (2) o score de risco do vendedor também é usado como **sinal de entrada do Agente de Risco de Entrega (Agente 2)** — assim, um pedido futuro feito com um vendedor já sinalizado nasce com risco mais alto na previsão, e é o Agente 2 (não o Agente 3) quem decide se vale comunicar proativamente o cliente sobre aquele pedido específico.

Usuários envolvidos Time de Marketplace/Seller Success (gestão de relacionamento com vendedores), Operações (decisões de priorização logística), diretoria comercial (decisões de retenção/desligamento de parceiros), Agente de Risco de Entrega (consumidor do score como sinal preditivo, não usuário humano).

Benefício esperado Ação direcionada aos vendedores de maior risco antes que impactem a experiência de um volume maior de clientes; input objetivo e baseado em dados para negociações comerciais e planos de melhoria; e previsões de atraso mais precisas no Agente 2 ao incorporar o histórico do vendedor.

Riscos Necessário considerar efeitos de sazonalidade e volume baixo (ex.: 1 pedido atrasado em 4 gera 25% de taxa de atraso) para não penalizar injustamente vendedores pequenos; governança clara sobre quais ações podem ser automatizadas vs. precisam de aprovação humana; viés de causa-raiz se os comentários de review forem poucos ou ambíguos.

3.4 Agente de Atendimento ao Cliente

Objetivo Responder automaticamente às dúvidas mais frequentes do cliente sobre status de pedido, prazo de entrega, política de troca/devolução e dados de pagamento,

escalando para atendimento humano apenas os casos que exigem julgamento.

Problema resolvido Com ~100 mil pedidos no período, a maior parte das interações de suporte provavelmente é repetitiva e de baixa complexidade (status de entrega, prazo, forma de pagamento), consumindo capacidade humana que poderia ser direcionada a casos mais complexos ou sensíveis.

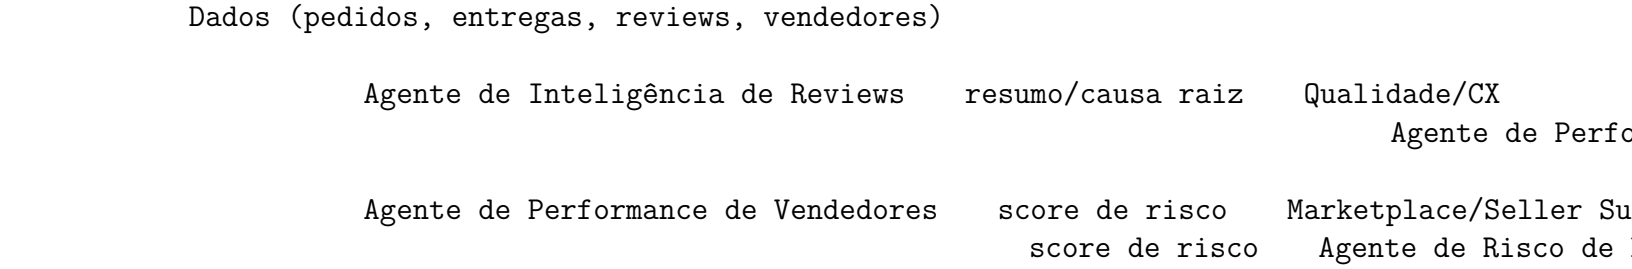
Dado que evidencia 97% dos pedidos são efetivamente entregues (baixo volume de exceções "duras"), mas 6,8% chegam atrasados e geram queda abrupta de satisfação — indicando um fluxo previsível e de alto volume de perguntas sobre "cadê meu pedido".

Usuários envolvidos Cliente final (canal principal de interação), time de Atendimento ao Cliente (recebe apenas os casos escalados), Logística (consome sinais do Agente de Risco de Entrega para enriquecer as respostas).

Benefício esperado Redução de custo e tempo de resposta no atendimento de baixa complexidade; experiência mais consistente para o cliente; liberação da equipe humana para casos de maior criticidade (ex.: produto errado, fraude, reclamações graves).

Riscos Necessidade de limites claros de escalonamento para evitar frustração em casos complexos; consistência das respostas depende da qualidade e atualização da base de conhecimento/dados conectados ao agente.

4 Como os agentes se conectam



Ponto-chave do fluxo: **só o Agente de Risco de Entrega fala com o cliente** (via Agente de Atendimento). O Agente de Performance de Vendedores atua nos bastidores — gestão de vendedores e alimentação de sinal para o Agente 2 — nunca expondo ao cliente o histórico de um vendedor específico.

A arquitetura conceitual completa (fontes de dados, entradas/saídas e interações) será detalhada em documento específico, a ser incorporado ao relatório executivo final.

5 Próximos passos sugeridos

- Validar com o grupo se os 4 agentes cobrem adequadamente os desafios citados pela Olist, ou se vale priorizar/reduzir para os 3 mínimos exigidos pelo desafio.
- Desenhar a arquitetura conceitual (item 3 do desafio) conectando estes agentes às fontes de dados.
- Estruturar os prompts (item 4 do desafio) para cada agente, usando a estrutura objetivo/contexto/ instrução/resultado esperado.